

MATERIAL DE ESTUDO · CAIXA

Machine Learning na Prática

Entendendo Modelos, Resultados, Acertos e Erros

Um guia visual, com exemplos e exercícios usando o Campeonato Brasileiro (2003–2025)

● 5 Algoritmos explicados

● 4 Métricas essenciais

● 5 Exercícios com gabarito

● Ponte para o crédito bancário

Índice

- 1 Os 4 tijolos: Acerto e Erro (VP, VN, FP, FN) a base de tudo
- 2 As Métricas: transformando acertos em notas acurácia, precisão, recall, F1
- 3 Os Modelos: como cada algoritmo pensa 5 modelos + analogias
- 4 Interpretando resultados: qual métrica olhar? o trade-off
- 5 Armadilhas do iniciante leakage, overfitting
- 6 A ponte para o seu trabalho na CAIXA crédito e risco
- 7 Checklist para começar resumo prático

● Como usar este material

Este guia tira suas principais dúvidas: (1) como cada **modelo** pensa, (2) o que cada **resultado** significa e por que importa, e (3) como ler os **acertos e erros**. Ao final de cada seção há **exercícios práticos com gabarito**. Faça as contas você mesmo — é assim que o conceito "cola".

● Lembre-se do seu piloto

Você já construiu o Portal dos Pokémon Lendários com 5 algoritmos e métricas como F1 e ROC AUC. Aqui aprofundamos esses mesmos conceitos, agora com o Brasileiro.

1. Os 4 tijolos: Acerto e Erro

Tudo em Machine Learning gira em torno de comparar a **previsão do modelo** com a **verdade (o gabarito)**. Dessa comparação nascem 4 situações. Domine estas 4 e você entende qualquer métrica.

★ **Alvo do exemplo** "O clube **JÁ FOI REBAIXADO?**" (Sim = 1, Não = 0)

Sigla	Nome	O que significa	Exemplo no Brasileiro
VP	Verdadeiro Positivo	Previu SIM e era SIM. Acerto!	Previu que o Vasco caiu — e ele caiu mesmo.
VN	Verdadeiro Negativo	Previu NÃO e era NÃO. Acerto!	Previu que o Flamengo não caiu — e não caiu.
FP	Falso Positivo	Previu SIM, mas era NÃO. Erro (alarme falso).	Previu que o São Paulo caiu — mas ele nunca caiu.
FN	Falso Negativo	Previu NÃO, mas era SIM. Erro (deixou passar).	Previu que o Cruzeiro não caiu — mas ele caiu.

● Dica de memória

A **1ª palavra** diz se o modelo ACERTOU (Verdadeiro) ou ERROU (Falso). A **2ª palavra** diz o que ele PALPITOU (Positivo = sim / Negativo = não). Então "Falso Positivo" = errou dizendo sim; "Falso Negativo" = errou dizendo não.

A Matriz de Confusão

É só organizar esses 4 números num quadro. Repare nas cores: **verde = acerto**, **vermelho = erro**.

	Modelo prevê: CAIU	Modelo prevê: NÃO caiu
Realmente CAIU	VP ✓ <i>acertou o "sim"</i>	FN X <i>deixou passar</i>
Na verdade NÃO caiu	FP X <i>alarme falso</i>	VN ✓ <i>acertou o "não"</i>

Exercício Prático 1 — Classifique os casos

Um modelo analisou clubes para prever "já foi rebaixado?". Classifique cada um como VP, VN, FP ou FN:

- 1) **Vitória** — Previu: CAIU · Real: caiu
- 2) **Palmeiras** — Previu: NÃO caiu · Real: não caiu
- 3) **São Paulo** — Previu: CAIU · Real: não caiu
- 4) **Coritiba** — Previu: NÃO caiu · Real: caiu
- 5) **Sport** — Previu: CAIU · Real: caiu

✓ Gabarito

1) **VP** (acertou o sim) · 2) **VN** (acertou o não) · 3) **FP** (alarme falso) · 4) **FN** (deixou passar) · 5) **VP**.

2. As Métricas: acertos viram notas

Contar VP, VN, FP e FN é ótimo — mas precisamos de **notas** para comparar modelos. Cada métrica combina esses números de um jeito, respondendo a uma pergunta diferente.

2.1 Acurácia — "No geral, quanto acertou?"

$$\text{Acurácia} = (\text{VP} + \text{VN}) / \text{Total}$$

Exemplo: em 45 clubes, o modelo acertou 38 (somando VP e VN). Acurácia = $38 / 45 = 84,4\%$.

● A grande armadilha

A acurácia **engana** quando um grupo é raro. Só 8 clubes têm "aproveitamento >50%". Um modelo preguiçoso que diz "NÃO" para TODOS os 45 acerta 37 = **82% de acurácia**! Parece ótimo, mas não achou **nenhum** dos 8 que importavam. Por isso nunca confie só na acurácia.

2.2 Precisão — "Quando aponta, acerta?"

$$\text{Precisão} = \text{VP} / (\text{VP} + \text{FP})$$

Foca só nos casos que o modelo disse SIM. Dos que ele apontou, quantos estavam certos? Mede a **confiabilidade do alerta**.

Exemplo: o modelo apontou 10 clubes como "campeão". Destes, 8 eram mesmo (VP=8) e 2 não (FP=2). Precisão = $8 / 10 = 80\%$.

● No banco

Precisão alta importa quando o alarme falso é caro — ex.: aprovar crédito para quem não paga (FP) gera prejuízo direto.

2.3 Recall (Captura) — "Achou todos que importam?"

$$\text{Recall} = \text{VP} / (\text{VP} + \text{FN})$$

Foca nos casos que REALMENTE eram SIM. Desses, quantos o modelo encontrou? Mede a **cobertura**.

Exemplo: existem 9 clubes campeões. O modelo achou 6 (VP=6) e deixou 3 passarem (FN=3). Recall = $6 / 9 = 66,7\%$.

● No banco

Recall alto importa quando deixar passar é caro — ex.: não detectar uma fraude ou perder um cliente de alto valor (FN).

2.4 F1-Score — "Qual o equilíbrio?" ★

$$F1 = 2 \times (\text{Precisão} \times \text{Recall}) / (\text{Precisão} + \text{Recall})$$

O F1 junta as duas num número só. É a **média harmônica** — ela pune desequilíbrios: se uma for baixa, o F1 despenca. Só fica alto quando **as duas** são boas. É a **métrica-estrela** para bases desbalanceadas como a sua.

● Veja a "mágica" da média harmônica (precisão 100%, recall 10%)

- Média comum: $(100 + 10) / 2 = 55\%$ → parece razoável, mas engana.
- F1 (harmônica): $2 \times (1,0 \times 0,1) / (1,0 + 0,1) = 18\%$ → revela que o modelo é ruim. ✓

Quadro-resumo das métricas

Métrica	Pergunta	Fórmula	Priorize quando...
Acurácia	% geral de acertos	$(VP+VN)/\text{Total}$	base equilibrada
Precisão	qualidade dos "sim"	$VP/(VP+FP)$	alarme falso é caro
Recall	cobertura dos "sim"	$VP/(VP+FN)$	deixar passar é caro
F1 ★	equilíbrio dos dois	$2 \cdot P \cdot R / (P+R)$	quer o balanço (seu caso!)

✎ Exercício Prático 2 — Calcule as 4 métricas (o mais importante!)

Um modelo previu "já foi campeão?" em 45 clubes e produziu esta matriz:

	Previu: Campeão	Previu: Não
Realmente campeão	VP = 7	FN = 2
Não é campeão	FP = 3	VN = 33

Sua missão: calcule Acurácia, Precisão, Recall e F1 antes de ver o gabarito!

✓ Gabarito passo a passo

Acurácia = $(7 + 33) / 45 = 40/45 = 88,9\%$

Precisão = $7 / (7 + 3) = 7/10 = 70,0\%$ → dos 10 que apontou, 7 eram campeões.

Recall = $7 / (7 + 2) = 7/9 = 77,8\%$ → dos 9 campeões reais, achou 7.

F1 = $2 \times (0,70 \times 0,778) / (0,70 + 0,778) = 73,7\%$

Leitura: a acurácia parece altíssima (88,9%), mas é "inflada" pelos 33 acertos fáceis de "não campeão". O **F1 (73,7%)** é mais honesto sobre a real capacidade de achar campeões.

3. Os Modelos: como cada um pensa

Agora que você lê os resultados, vamos entender **quem os produz**. Cada modelo tem uma "personalidade" — uma forma diferente de decidir. Aqui vão os 5 recomendados para começar.

1 Naive Bayes — O Apostador de Probabilidades

Como pensa: calcula a probabilidade de cada resposta com base em cada atributo e multiplica tudo.

"Times com saldo alto são campeões em 70% dos casos; com muitos jogos, 60%... juntando, esse time tem X% de chance."

✓ **Brilha em:** rápido e ótimo com **poucos dados** (seu caso). Foi o melhor F1 no seu Pokémon (70,6%).

! **Atenção:** assume que os atributos são independentes — mas Vitórias e Gols andam juntos. Use poucas features distintas.

2 KNN (K-Vizinhos) — Me diga com quem andas...

Como pensa: para classificar um time, olha os K clubes mais parecidos e copia a resposta da maioria.

"Para o Cruzeiro, olho os 5 clubes de estatísticas mais próximas. Se 4 têm aproveitamento >50%, ele provavelmente também tem."

✓ **Brilha em:** muito intuitivo, sem treino complexo. O "K" é quantos vizinhos consultar (3, 5, 7...).

! **Atenção:** exige normalizar os dados (feito no código) — senão "Jogos" (até 894) domina "Artilheiro" (até 5).

3 Regressão Logística — O Juiz que dá Pesos

Como pensa: dá um peso a cada atributo. Positivo empurra para "sim", negativo para "não". Soma e decide.

"Cada +10 de saldo vale +2 pró-campeão; cada rebaixamento vale -5. Somo e vejo se passa do corte."

✓ **Brilha em:** a melhor para **ler a direção** de cada fator. É a rainha do crédito bancário.

! **Atenção:** só captura relações "em linha reta" (lineares).

4 Árvore de Decisão — O Jogo de Perguntas

Como pensa: cria uma sequência de perguntas sim/não que afunilam até a resposta.

"Saldo > 100? → Sim → Mais de 800 jogos? → Sim → então é CAMPEÃO."

✓ **Brilha em:** fácil de entender e **explicar** (você vê as regras). Ótima para justificar decisões.

! **Atenção:** sozinha, tende a "decorar" o treino (overfitting). Compare com Random Forest.

5 Random Forest — O Conselho de Árvores

Como pensa: cria muitas árvores diferentes e faz uma votação. A maioria vence.

"87 das 100 árvores disseram 'campeão' → resposta final: CAMPEÃO."

✓ **Brilha em:** mais estável e confiável que uma árvore só. Mostra a importância de cada variável.

! **Atenção:** menos transparente — são 100 árvores, difícil ver "a regra" exata.

Quadro comparativo dos modelos

Modelo	Personalidade	Força principal	Explicável?
Naive Bayes	Apostador	Rápido, bom em base pequena	Média
KNN	"Com quem andas"	Muito intuitivo	Média
Regressão Logística	Juiz de pesos	Mostra a direção do fator	Alta
Árvore de Decisão	Perguntas	Fácil de explicar	Alta
Random Forest	Conselho	Estável e confiável	Baixa

● Por que "explicável" importa no banco

Se você nega um crédito, precisa justificar ao cliente e ao regulador **por quê**. Regressão Logística e Árvore mostram o motivo; Random Forest acerta mais, mas é "caixa-preta". Nem sempre o mais preciso é o mais adequado.

✎ Exercício Prático 3 — Escolha o modelo certo

- A) "Preciso EXPLICAR ao cliente por que o crédito foi negado."
- B) "Tenho pouquíssimos dados e quero algo rápido para um primeiro teste."
- C) "Quero o resultado mais estável possível, sem me importar em explicar."
- D) "Quero entender se 'saldo de gols' ajuda ou atrapalha a previsão."

✓ Gabarito

- A) **Árvore de Decisão** (mostra as regras) · B) **Naive Bayes** (rápido, base pequena) · C) **Random Forest** (estável) · D) **Regressão Logística** (mostra a direção/peso de cada fator).

4. Interpretando resultados

A pergunta que mais gera dúvida: "o modelo é bom?". **Depende do que você quer!** Veja como a mesma situação conta histórias diferentes.

O caso dos dois modelos

Dois modelos tentam achar os 9 clubes campeões. Veja o contraste:

Modelo	VP	FP	FN	Precisão	Recall	F1
A (cauteloso)	5	1	4	83%	56%	67%
B (generoso)	8	6	1	57%	89%	70%

● Como interpretar?

- O **Modelo A** é CAUTELOSO: quando diz "campeão", quase sempre acerta (precisão 83%), mas deixa 4 escaparem (recall baixo).
- O **Modelo B** é GENEROSO: acha quase todos (recall 89%), mas dá muitos alarmes falsos (precisão 57%).
- **Qual é melhor?** Se errar um alarme é caro → escolha A. Se deixar passar é caro → escolha B. O F1 (70% vs 67%) diz que, no equilíbrio, B leva leve vantagem.

O "trade-off" (cabo de guerra)

Precisão e recall costumam puxar para lados opostos. Melhorar um piora o outro. Não existe "modelo perfeito" — existe o modelo **adequado ao seu objetivo**. O F1 é o juiz do equilíbrio.

● O limiar (threshold) controla esse cabo de guerra

O modelo gera uma probabilidade (ex.: 0,62) e o limiar (padrão 0,50) decide o sim/não. Baixar → mais "sim" → sobe recall, cai precisão. Subir → mais cauteloso. No seu Pokémon, a dica era baixar de 0,50 para 0,35 para capturar mais lendários — é exatamente isso!

📝 Exercício Prático 4 — Qual métrica priorizar?

- A) Um banco quer JAMAIS aprovar crédito para um mau pagador, mesmo que negue alguns bons.
- B) Uma campanha quer alcançar o MÁXIMO de clientes com chance de contratar, mesmo ligando para alguns sem interesse.
- C) Você quer uma avaliação geral e equilibrada do modelo.

✓ Gabarito

A) **Precisão** (evitar o FP é prioridade) · B) **Recall** (não deixar passar/FN ninguém com potencial) · C) **F1** (equilíbrio).

5. Armadilhas do iniciante

● Vazamento de Dados (Data Leakage)

Usar como entrada uma coluna que "entrega a resposta". Ex.: prever "já foi campeão?" usando a coluna "Títulos". O modelo acerta 100%... mas não aprendeu nada — colou. **Solução:** não selecionar a coluna proibida de cada alvo.

Ao prever...	NÃO use como entrada
Já foi Campeão	Títulos
Já foi Rebaixado	Rebaixamentos
Aproveitamento >50%	Aproveitamento, Vitórias, Empates

● Overfitting (o "decoreba")

Quando o modelo decora o treino em vez de aprender o padrão. Vai bem no treino e mal em casos novos — como o aluno que decora a lista mas erra a prova. **Sinal:** ótimo no treino, ruim no teste. Random Forest ajuda a evitar.

● Treino e Teste

Separe a base: o modelo APRENDE no treino (ex.: 70%) e é AVALIADO no teste (ex.: 30%), que nunca viu. Só assim medimos se aprendeu de verdade. Com 45 clubes, o teste tem ~14 linhas — use validação cruzada para estabilizar.

✎ Exercício Prático 5 — Verdadeiro ou Falso?

- A) Uma acurácia de 90% sempre significa um ótimo modelo.
- B) Se eu incluir a coluna "Rebaixamentos" para prever "já foi rebaixado", o resultado será confiável.
- C) Um modelo com 100% de acerto no treino e 55% no teste provavelmente está com overfitting.

✓ Gabarito

A) **FALSO** — em base desbalanceada, 90% pode ser só o modelo dizendo "não" sempre. · B) **FALSO** — é vazamento de dados; vai "colar". · C) **VERDADEIRO** — decorou o treino e não generalizou.

6. A ponte para a CAIXA

O melhor de tudo: cada pergunta do Brasileiro **espelha** um problema real do banco. Você está treinando o raciocínio de um modelo de crédito com futebol.

No Brasileiro...	Equivale no banco a...
Prever "Já foi Rebaixado"	Prever inadimplência de um cliente
Prever "Já foi Campeão"	Identificar cliente de alto valor (private)
Ajustar o limiar de decisão	Definir a política de aprovação de crédito
Um Falso Positivo (FP)	Aprovar crédito para quem não paga (prejuízo)
Um Falso Negativo (FN)	Negar crédito a um bom cliente (venda perdida)
Importância das variáveis	Entender o que leva à inadimplência

● Conclusão

A lógica é idêntica: algoritmos, métricas, limiar, acertos e erros. Quando levar para a CAIXA, é só trocar "gols" por "renda" e "saldo de gols" por "histórico de pagamento". Dominar isso com o Brasileiro é **dominar credit scoring**.

7. Seu checklist para começar

- Olhe primeiro o **F1** (não a acurácia) — sua base é desbalanceada.
- Entenda os erros: **FP = alarme falso**; **FN = deixou passar**. Pergunte sempre qual custa mais.
- Comece com Naive Bayes, KNN, Regressão Logística, Árvore e Random Forest.
- Não selecione a coluna que "entrega a resposta" (anti-leakage).
- Use poucas features distintas (ajuda o Naive Bayes).
- Prefira modelos explicáveis pensando no uso bancário.
- Ajuste o limiar para equilibrar precisão e recall conforme seu objetivo.

Fim do guia. Material de estudo do Simulador de ML do Brasileiro — Hart Botelho, CAIXA.
Próximo passo sugerido: transformar a base no simulador interativo, nos moldes do portal Pokémon.